

**DOMINIO CONSERVACIÓN
INVESTIGACIÓN Y ESTUDIOS
PROGRAMA FOTOMONITOREO
Resultados de desempeño de Megadetector V5**

Índice:

- I. INTRODUCCIÓN**
- II. DEFINICIONES RESPECTO DE IA, EVALUACIÓN DE DESEMPEÑO, Y MÉTRICAS DE EVALUACIÓN.**
- III. METODOLOGÍA**
- IV. RESULTADOS**
- V. DISCUSIÓN Y CONCLUSIONES**

I. INTRODUCCIÓN

A continuación, se presenta la evaluación de desempeño de Megadetector V5a para detectar imágenes con animales. Para esto, se emplearon las fotos de cámara trampa tomadas entre los años 2022 a 2024 en Bosque Pehuén (BP).

El propósito original de la evaluación era determinar la confianza y configuración requerida del software para facilitar el análisis de imágenes. Debido a la sensibilidad de modelos de IA en su desempeño de acuerdo a las bases de datos que se emplean durante su entrenamiento, era necesario en primer lugar determinar el desempeño de Megadetector en un ecosistema como el que se observa en Bosque Pehuén. Es solo a partir de estos resultados que se puede tomar una decisión informada respecto de la utilidad de emplear este protocolo de análisis.

En segundo lugar, esta evaluación también es fundamental para la realización de informes de evaluación de fotomonitoreo en la etapa de control de calidad de los resultados, como se sugiere en Silva-Rodríguez et al. (2025).

A continuación, se aclaran algunos conceptos y puntos clave a entender para contextualizar esta evaluación de desempeño, para después pasar a los resultados de la evaluación.

II. DEFINICIONES RESPECTO DE IA, EVALUACIÓN DE DESEMPEÑO, Y MÉTRICAS DE EVALUACIÓN.

En primer lugar, el uso de IA para detectar animales en imágenes de cámaras trampa provee dos beneficios sustanciales:

1. **Eficiencia y Escalabilidad:** Estos sistemas permiten procesar grandes volúmenes de imágenes de manera rápida, lo que facilita el monitoreo de la biodiversidad y la toma de decisiones en proyectos de conservación; y
2. **Ahorro de Recursos:** Automatizar la identificación reduce la necesidad de revisión manual, lo que disminuye los costos y el tiempo invertido en el análisis.

Dicho esto, existen también varias deficiencias o límites en el desempeño de estos programas que, de no ser considerados, pueden acarrear consecuencias graves durante el análisis de los datos. Fundamentalmente los problemas son:

1. **Errores de Clasificación:** Pueden confundir animales con fondos o elementos visuales similares, especialmente en condiciones de baja iluminación o con animales parcialmente ocultos.
2. **Dependencia de Datos de Entrenamiento:** Si los datos usados para entrenar el modelo no son representativos de todas las condiciones o especies, se pueden producir sesgos y errores.
3. **Generalización Limitada:** Los modelos pueden tener dificultades para generalizar a nuevas regiones o especies no incluidas en su entrenamiento, reduciendo su efectividad en escenarios distintos.

Estas limitaciones requieren una atenta consideración al momento de decidir la metodología de análisis que se emplea con las imágenes para evitar que en el proceso se pierda valiosa información respecto de la biodiversidad del área. En particular, se debe analizar si el programa es confiable en la tarea de detectar o identificar especies animales de manera automática, para que efectivamente ésta pueda producir los beneficios mencionados más arriba.

En el contexto de la evaluación de desempeño de un programa de este tipo, esto se realiza revisando los resultados predichos por el programa de IA contra los resultados obtenidos por una revisión manual por parte de los investigadores de un mismo banco de datos. Los resultados posibles durante esta evaluación son:

Predicción IA	1	Verdadero positivo	Falso positivo (error tipo I)
	0	Falso negativo (error tipo II)	Verdadero negativo
		1	0
		Referencia humana	

Verdaderos Positivos (VP): El modelo identifica correctamente la presencia de un animal en la imagen.

Verdaderos Negativos (VN): El modelo reconoce correctamente la ausencia de un animal cuando realmente no hay ninguno.

Falsos Positivos (FP): El modelo identifica erróneamente la presencia de un animal cuando en realidad no hay ninguno.

Falsos Negativos (FN): El modelo no detecta la presencia de un animal que en realidad está presente.

Dependiendo del **umbral de confianza** que uno asigne (el porcentaje de confianza bajo el cual el programa clasificará las imágenes como vacías o con un animal), el programa tenderá a generar más errores tipo I o tipo II. Lo importante es entender cómo se desempeña el programa para decidir qué umbral mejor satisface las necesidades de la investigación que se esté realizando.

Métricas para Evaluar el Desempeño

Exhaustividad (*Recall*): Mide la capacidad del modelo para identificar correctamente todos los casos reales positivos. Se define como la proporción de verdaderos positivos sobre la suma de verdaderos positivos y falsos negativos.

Fórmula:

$$Recall = \frac{VP}{VP+FN}$$

Precisión (*Precision*): Evalúa la exactitud de las predicciones positivas del modelo. Se define como la proporción de verdaderos positivos sobre la suma de verdaderos positivos y falsos positivos.

Fórmula:

$$Precision = \frac{VP}{VP+FP}$$

Puntaje F1: Es la media armónica entre precisión y exhaustividad, proporcionando una medida única que equilibra ambas métricas. Es útil cuando se necesita un balance entre identificar correctamente todos los casos positivos y mantener baja la tasa de falsas alarmas.

Fórmula:

$$F1 = 2 * \left(\frac{PRECISION * RECALL}{PRECISION + RECALL} \right)$$

Tanto la exhaustividad del modelo como su precisión serán afectados por el umbral de confianza que uno fije, en donde una menor confianza genera mayor exhaustividad y menor precisión, y donde un mayor umbral de confianza genera menor exhaustividad y mayor precisión. Es por esto también que se emplea la métrica F1, para evaluar el balance entre ambos tipos de métricas.

Por último, otro concepto relevante para la discusión del desempeño del programa se refiere a la consistencia interna del programa respecto de su nivel de confianza y nivel acierto en sus predicciones.

La **calibración** se refiere a la capacidad del modelo para asignar probabilidades que reflejen correctamente la incertidumbre de sus predicciones. En otras palabras, si el modelo predice que hay un 80% de probabilidad de que una imagen contenga un animal, en condiciones bien calibradas, aproximadamente el 80% de esas predicciones deberían ser correctas. Una buena calibración es fundamental porque:

- **Confianza en las Predicciones:** Permite a los investigadores y responsables de la toma de decisiones confiar en el valor predictivo proporcionado por el modelo.
- **Umbrales de Decisión:** Facilita el ajuste de umbrales para clasificar una imagen como positiva o negativa, optimizando el balance entre errores de tipo I y II.
- **Interpretabilidad:** Mejora la interpretabilidad del sistema al ofrecer una estimación realista de la probabilidad de cada predicción, lo cual es esencial en aplicaciones críticas de conservación y monitoreo.

Esta consistencia del modelo es valiosa para entender mejor las características de su desempeño, pero no refleja necesariamente la utilidad del modelo para un proceso de investigación. Esto en tanto que un modelo mal calibrado igualmente puede obtener altísimos puntajes de exhaustividad si se ajustan los umbrales de confianza adecuadamente. Sin embargo, una baja calibración también da cuenta al equipo investigador de la necesidad de complementar los datos del modelo para lograr resultados más consistentes en su territorio.

III. METODOLOGÍA

La metodología para evaluar el desempeño del modelo consiste en un procedimiento estándar para medir la arquitectura de diversos tipos de algoritmos de aprendizaje automático. En todos los casos, se deben comparar las predicciones del modelo con un conjunto de datos de referencia (revisado y avalado por revisores humanos).

Para llevar a cabo esta evaluación, la base de datos que se utilizó consiste en 7.136 imágenes tomadas por las cámaras trampa durante los años 2022 y 2023 en BP. Estas imágenes fueron analizadas por la versión de Megadetector V5a y V5b (aquí solo se muestran los resultados de la versión V5a al ser muy similares en términos de desempeño). Se empleó un script en Python para que Megadetector analice las imágenes y entregue sus resultados en formato cvs.


Para el análisis de referencia (realizado por el equipo investigador), se tomaron las mismas imágenes y se ingresaron a *Timelapse Image Analyzer*, donde se procedió a clasificar el banco de imágenes de acuerdo si estas contenían animales, personas, vehículos, o si estaban vacías de estos elementos. Luego se descargó la clasificación en un archivo cvs para comparar los resultados.

Para el proceso de evaluación se utilizó el programa R, siguiendo los pasos descritos por Velez, J. y J. Fieberg (2022).

IV. RESULTADOS.

Una vez comparados los resultados de Megadetector con la tabla generada por el equipo investigador, se observa que en general el programa logra bien su objetivo de identificar imágenes con animales, siendo bastante efectivo a la hora de descartar imágenes que no contienen animales. Esto puede observarse a partir de la matriz de confusión (Ilustración 1) que indica la frecuencia observada respecto de los resultados de clasificación del programa. (se empleó un umbral de confianza de 65% para calcular este resultado, aunque un análisis de sensibilidad después indica una mejor configuración para su desempeño).

Ilustración 1 Matriz de confusión del modelo Megadetector V5a con un umbral de confianza de 65%.



Como se observa, la gran mayoría de las veces el programa acierta en los casos de verdaderos positivos y verdaderos negativos. Traducido a las métricas de desempeño descritas más arriba, se observa que, con un umbral de confianza de 65%, Megadetector obtiene un 86% de precisión, un 92% de exhaustividad, y un puntaje F1 de 0.88 (Tabla 1). En otras palabras, Megadetector acierta el 86% de las veces que dice que una imagen tiene un animal, y efectivamente reconoce el 92% de las imágenes que tienen un animal.

Tabla 1 Resultados de desempeño de precisión, exhaustividad y puntaje F1 para Megadetector V5a con un límite de confianza de 0.65.

Class	Precision	Recall	F1
Animal	0.86	0.92	0.88

Si bien estos resultados son bastante altos, se deben comparar a los observados por otros investigadores en otras regiones del mundo. Si comparamos con los resultados que observaron Velez, J. y J. Fieberg (2022), donde obtuvieron una precisión de 98%, exhaustividad de 93%, y un puntaje F1 de 0.96, se evidencia que Megadetector se desempeña sustancialmente peor con las imágenes obtenidas de Bosque Pehuén. Esto ya

pone en evidencia una limitación del programa para analizar imágenes de nuestro ecosistema, y sugiere la necesidad de promover el entrenamiento del mismo con bases bancos de imágenes representativos de nuestra región.

Dado que Megadetector entrega umbrales de confianza en sus resultados, es posible medir la sensibilidad de sus resultados dependiendo del umbral de confianza. Esto permite determinar el umbral que mejor satisface las necesidades de investigación del equipo. Por ejemplo, mientras más bajo uno fija el umbral de confianza, más exhaustivo va a ser el programa para encontrar imágenes con animales, aunque también significa que va a ser menos preciso, lo que significa que va a generar más falsos positivos (ej. creer que una rama es un animal). Esto es deseable si el equipo investigador quiere asegurarse que no se pase por alto ninguna imagen con un animal. Dada la naturaleza del monitoreo que se hace en BP, que busca conocer la riqueza del área, esta pareciera ser la prioridad, por lo que el umbral que se elija debe en primer lugar garantizar un alto porcentaje de exhaustividad. Para definir mejor qué umbral específico deberíamos elegir al momento de usar las predicciones de Megadetector, la Tabla 2 resume los umbrales de confianza que deben elegirse para obtener porcentajes de exhaustividad de 97% o más altos, con los consecuentes valores de precisión y F1 que le corresponden.

Tabla 2 Valores de Precisión, exhaustividad y F1 según umbral de confianza.

Precision	Recall	F1	conf_threshold
0.61	0.99	0.76	0.1
0.63	0.99	0.77	0.11
0.64	0.99	0.77	0.12
0.65	0.98	0.78	0.13
0.66	0.98	0.79	0.14
0.67	0.98	0.79	0.14
0.67	0.98	0.8	0.15
0.68	0.98	0.8	0.16
0.69	0.98	0.81	0.17
0.7	0.98	0.81	0.18
0.71	0.97	0.82	0.19
0.71	0.97	0.82	0.2
0.72	0.97	0.82	0.21
0.72	0.97	0.83	0.22

0.73	0.97	0.83	0.23
0.73	0.97	0.84	0.23
0.74	0.97	0.84	0.24
0.75	0.97	0.84	0.25
0.75	0.97	0.85	0.26
0.76	0.97	0.85	0.27
0.76	0.97	0.85	0.28
0.77	0.97	0.86	0.29
0.77	0.97	0.86	0.3
0.77	0.97	0.86	0.31
0.78	0.97	0.86	0.32
0.78	0.97	0.86	0.32
0.78	0.97	0.86	0.33
0.78	0.97	0.87	0.34
0.79	0.97	0.87	0.35
0.79	0.97	0.87	0.36
0.8	0.97	0.88	0.37
0.8	0.97	0.88	0.38

(También hay gráficos de calibración que muestran la variación de los resultados de acuerdo a umbrales de confianza que no sé si incluir para no continuar alargando el informe. La conclusión que entregan es que Megadetector no es tan bien calibrado para trabajar con nuestro ecosistema, ya que el desempeño del programa no sigue curvas claras de resultados).

V. DISCUSIÓN Y CONCLUSIONES

Los resultados de esta investigación sugieren 2 cosas. Para el equipo de investigación, demuestra que, con un correcto umbral de confianza, Megadetector es capaz de reconocer virtualmente todas las imágenes con animales, a costa de confundirse con algunas ramas, piedras, o sombras. Esto es positivo dado que eliminar estos errores no interfiere mucho el flujo de trabajo de análisis, ya que las imágenes reconocidas por Megadetector igualmente debieran ser analizadas por el equipo para clasificar las especies. El hecho que el programa descarte correctamente la gran mayoría de las imágenes “vacías” ya reduce considerablemente el tiempo de análisis de las imágenes.

Por otro lado, los resultados también demuestran que hay amplio espacio de crecimiento para el programa, demostrando resultados sustancialmente peores que los observados en otras investigaciones. Esto se debe, sin dudas, a su capacidad limitada de generalizar su algoritmo a regiones y ecosistemas con los que no fue entrenado. Esto también indica la necesidad de proveer este tipo de datos a los investigadores que desarrollan estos modelos, para mejorar su desempeño. A este respecto, sería valioso discutir esta posibilidad con otros investigadores del sur de Chile, para acordar y confeccionar un banco de imágenes que pueda ser enviado al equipo de *Microsoft AI for Good Lab*, quienes manejan el repositorio *Pytorch Wildlife*, donde se aloja el modelo.

Referencias:

- Velez, J. and J. Fieberg. 2022. *Guide for using artificial intelligence platforms for camera-trap data processing*. <https://ai-camtraps.netlify.app/>
- Silva-Rodríguez, E. A., Cortés, E. I., Vasquez-Ibarra, V., Gálvez, N., Cusack, J., Ohrens, O., Moreira-Arce, D., Fariás, A. A., & Infante-Varela, J. (2025). A protocol for error prevention and quality control in camera trap datasets. *Journal of Applied Ecology*, 00, 1–10. <https://doi.org/10.1111/1365-2664.70010>.